





Centro Brasileiro de Pesquisas Físicas



Métodos para Análise de grande volume de dados e Astroinformática

Clécio Roque De Bom – debom@cbpf.br

clearnightsrthebest.com



Error Theory

O *mensurando*¹ é a grandeza a ser determinada num processo de medição. Como regra geral, *valor verdadeiro do mensurando é uma quantidade sempre desconhecida*. Isto é, mesmo após a medição, o valor verdadeiro do mensurando só pode ser conhecido aproximadamente, devido a *erros de medição*.

Se y_v é o valor verdadeiro de um mensurando e y é o resultado de uma medição, o *erro* em y é definido por

$$\eta = y - y_v. \quad (3.1)$$



Error Theory

Geralmente, o erro η em um valor experimental y tem diversas causas⁴. Isto significa que o erro total η pode ser escrito como uma soma de q erros elementares $\eta_1, \eta_2, \dots, \eta_q$:

$$\eta = \eta_1 + \eta_2 + \dots + \eta_q. \quad (3.2)$$




Figura 3.1. Função gaussiana de probabilidades. A probabilidade ΔP_i de obter uma medida y no intervalo Δy é a área ΔS . A área total sob a curva é 1, devido à condição de normalização 2.11.

Error Theory

A distribuição de Laplace-Gauss ou distribuição gaussiana de erros é definida pela função de densidade de probabilidade⁵ dada por

$$G(y) = \frac{1}{\sigma \sqrt{2\pi}} e^{-\frac{1}{2} \left(\frac{y-\mu}{\sigma} \right)^2}, \quad (3.3)$$

Teorema do Limite Central

Erros aleatórios independentes η_1, η_2, \dots e η_q são admitidos como tendo distribuições de probabilidade quaisquer com variâncias finitas e tais que nenhum η_i particular é muito maior que os demais. Nestas condições, se o erro total é $\eta = \eta_1 + \eta_2 + \dots + \eta_q$, então, a distribuição de erros para η converge para uma distribuição gaussiana, no limite $q \rightarrow \infty$.

Fundamental Concepts

Average

$$\bar{x} = \frac{x_1 + x_2 + \dots + x_n}{n} = \frac{1}{n} \sum_{i=1}^n x_i$$

Variance

$$s^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2,$$

Standard Deviation

$$s = \sqrt{\frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2}$$



Uncertainty


Se y_v é o valor verdadeiro de um mensurando e y é o resultado de um processo de medição, a probabilidade $P(\delta)$ de se obter um resultado y no intervalo

$$y_v - \delta < y < y_v + \delta \quad (4.2)$$

pode ser obtida integrando-se a função densidade de probabilidade (Equação 2.10). Admitindo uma distribuição gaussiana para os erros,

$$P(\delta) = \frac{1}{\sigma_v \sqrt{2\pi}} \int_{y_v - \delta}^{y_v + \delta} e^{-\frac{1}{2} \left(\frac{y - y_v}{\sigma_v} \right)^2} dy, \quad (4.3)$$



Confidence Levels




Confidence Levels

<i>Incerteza</i>		<i>Intervalo de confiança</i>	<i>Confiança</i>
Incerteza padrão	σ_v	$(y - \sigma_v) < y_v < (y + \sigma_v)$	68,27 %
δ	$2\sigma_v$	$(y - 2\sigma_v) < y_v < (y + 2\sigma_v)$	95,45 %
δ	$3\sigma_v$	$(y - 3\sigma_v) < y_v < (y + 3\sigma_v)$	99,73 %
δ	$1,645\sigma_v$	$(y - \delta) < y_v < (y + \delta)$	90 %
δ	$2,576\sigma_v$	$(y - \delta) < y_v < (y + \delta)$	99 %
Erro provável	Δ	$(y - \Delta) < y_v < (y + \Delta)$	50 %




Tensions?




Confidence Levels - Percentil



Confidence Levels - Percentil



Probabilities



$$p(A \cup B) = p(A) + p(B) - p(A \cap B)$$

$$p(A \cap B) = p(A|B)p(B) = p(B|A)p(A)$$

Probabilities

$$p(A \cap B) = p(A|B)p(B) = p(B|A)p(A)$$

A = hit head on door frame, B = { is tall, is average, is short }

$P(A) = P(A|\text{is tall}) + P(B|\text{is average}) + P(C|\text{is short})$

if A and B are independent, then

$$p(A, B) = p(A)p(B)$$



Types of Errors

Physics \ ML	Aleatoric	Epistemic
Statistical	noise in data, stdev of measurements (noise in period T)	—
Systematic	noise in data, not stdev of measurements (noise in length L)	model fidelity, not stdev of measurements (far from training set)

Expected Values

$$\mathbf{E}[X] = \int_{\mathbb{R}} x f(x) dx,$$

$$\mathbf{E}[g(X)] = \int_{\mathbb{R}} g(x) f(x) dx.$$





Centro Brasileiro de Pesquisas Físicas



Métodos para Análise de grande volume de dados e Astroinformática

Clécio Roque De Bom – debom@cbpf.br

clearnightsrthebest.com

